Algoritmos Genéticos aplicados a la optimización de carteras financieras

Un enfoque basado en el Modelo de Markowitz para la asignación óptima de capital

Abstract

El presente trabajo explora la utilización de un algoritmo genético para determinar la distribución del capital dentro de una cartera de inversión, con el objetivo de maximizar el rendimiento esperado y minimizar el riesgo asociado. Se adopta el Modelo de Markowitz, o Teoría Moderna de Carteras, como marco de referencia teórico, definiendo la rentabilidad a partir de los retornos históricos de los activos y el riesgo mediante la desviación estándar de los retornos de la cartera. El problema se formula como una optimización bi-objetivo sujeta a restricciones de asignación de capital, y se implementan dos funciones de fitness: una basada en la combinación de rentabilidad y riesgo mediante un parámetro de penalización λ, y otra basada en el Índice de Sharpe. Se utilizan datos históricos mensuales correspondientes a los últimos cinco años y una cartera de referencia compuesta por siete instrumentos financieros. Se analiza la evolución de las poblaciones durante las generaciones y se comparan las soluciones obtenidas mediante ambas funciones de fitness.

Palabras Clave

algoritmos genéticos; optimización de carteras; Modelo de Markowitz; rentabilidad; riesgo; Índice de Sharpe.

1. Introducción

La selección de una cartera de inversión constituye un problema de optimización en el que se busca determinar cómo distribuir un capital disponible entre diferentes instrumentos financieros, procurando alcanzar un equilibrio entre rentabilidad y riesgo. Esta decisión resulta especialmente compleja cuando se consideran múltiples activos con comportamientos, niveles de volatilidad y relaciones entre sus rendimientos diferentes.

El Modelo de Markowitz, también denominado Teoría Moderna de Carteras, proporciona un marco matemático para estudiar este problema. Su enfoque considera tanto el rendimiento esperado de cada activo como la relación existente entre ellos mediante la matriz de covarianzas. De esta manera, la diversificación permite analizar no solamente la volatilidad individual de cada instrumento, sino también cómo se comportan conjuntamente.

El presente trabajo busca determinar, mediante un algoritmo genético, una distribución del capital entre una cartera de referencia previamente definida. La selección de los instrumentos se mantiene fija durante los experimentos, mientras que el algoritmo determina la proporción asignada a cada uno, respetando restricciones de inversión mínima y máxima.

La utilidad práctica del enfoque consiste en disponer de un procedimiento computacional que permita obtener una cartera a partir de información histórica disponible al momento de la ejecución. El análisis se realiza utilizando retornos mensuales correspondientes a los últimos cinco años.

El trabajo se organiza de la siguiente manera. En primer lugar, se presenta la formulación del problema y la cartera de referencia. Luego se desarrolla el marco matemático utilizado para calcular rentabilidad y riesgo y se describe la implementación del algoritmo genético. Posteriormente se presentan las funciones de fitness utilizadas y el procedimiento experimental. Finalmente se analizan los resultados, las limitaciones del enfoque y posibles líneas de trabajo futuro.

2. Formulación del problema

La pregunta que orienta la investigación es:

> *¿Puede un algoritmo genético determinar una distribución óptima del capital entre un conjunto de activos financieros, maximizando el rendimiento esperado y minimizando el riesgo de la cartera?*

El problema presenta dos objetivos contrapuestos. Por un lado, se busca maximizar la rentabilidad esperada de la cartera y, por otro, minimizar su riesgo.

Para representar el compromiso entre ambos objetivos, se incorpora un parámetro de trade-off denominado λ, que permite controlar la importancia relativa asignada al riesgo frente a la rentabilidad. De esta manera, el problema puede abordarse mediante una función de fitness que combina ambos objetivos, desarrollada posteriormente en la sección de funciones de fitness.

Formalmente:

$$\max E(R_p) \quad \wedge \quad \min \sigma_p. \tag{1}$$

La totalidad del capital debe ser distribuida entre los instrumentos seleccionados:

$$\sum_{i=1}^{n} w_i = 1. \tag{2}$$

Además, se establecen restricciones de inversión mínima y máxima para cada activo. En particular, cada activo debe recibir como mínimo un 5 % del capital disponible y como máximo un 25 %:

$$0.05 \leq w_i \leq 0.25, \qquad i = 1, \ldots, n. \tag{3}$$

Estas restricciones permiten representar una condición adicional propia de una cartera de inversión, evitando tanto la exclusión completa de un activo como una concentración excesiva del capital.

2.1 Cartera de referencia

La cartera utilizada en el trabajo se mantiene fija y está compuesta por siete activos. El objetivo de esta selección es proporcionar al algoritmo un conjunto heterogéneo de alternativas de inversión.

Cuadro 1: Activos de la cartera de referencia.

Tipo	Activo	Ticker
ETF	S&P 500	SPY
ETF	Oro	GLD
ETF	Invesco QQQ Trust	QQQ
Acción	YPF	YPF
Acción	Coca-Cola	KO
Acción	Mercado Libre	MELI
Acción	NVIDIA	NVDA

Se eligió esta cartera debido a que combina exposición a un índice accionario amplio, materias primas y empresas pertenecientes a diferentes sectores económicos. Esta heterogeneidad permite analizar cómo el algoritmo distribuye el capital cuando los activos presentan diferentes características históricas.

3. Modelo de Markowitz

El modelo utilizado como referencia parte de la relación entre rentabilidad y riesgo. Una cartera eficiente busca obtener el mayor rendimiento posible para un nivel determinado de riesgo, o bien minimizar el riesgo para un nivel determinado de rendimiento [1].

3.1 Rentabilidad

El rendimiento esperado de la cartera se obtiene como la suma ponderada de los rendimientos esperados de cada activo [1]:

$$E(R_p) = \sum_{i=1}^{n} w_i \mu_i, \tag{4}$$

donde w_i representa la proporción invertida en el activo i, μ_i su rendimiento esperado y n la cantidad de activos.

Los rendimientos esperados se estiman a partir de los retornos históricos mensuales. Para cada período se calcula:

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}}, \tag{5}$$

donde $P_{i,t}$ representa el precio del activo i en el período t.

3.2 Riesgo

En este trabajo el riesgo se mide mediante la volatilidad de los rendimientos, representada por la desviación estándar de la cartera [1]. La expresión utilizada es:

$$\sigma_p = \sqrt{w^T \Sigma w}, \tag{6}$$

donde w es el vector de pesos de la cartera y Σ es la matriz de covarianzas de los rendimientos históricos.

La utilización de la matriz de covarianzas permite considerar no solamente la variabilidad individual de cada activo, sino también cómo se comportan los activos conjuntamente [1].

3.3 Matriz de covarianzas

La matriz puede representarse como:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \mathrm{Cov}(R_1, R_2) & \cdots \\ \mathrm{Cov}(R_2, R_1) & \sigma_2^2 & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}. \tag{7}$$

Los elementos de la diagonal corresponden a las varianzas individuales:

$$\sigma_i^2 = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \mu_i)^2. \tag{8}$$

Los elementos fuera de la diagonal corresponden a las covarianzas:

$$\mathrm{Cov}(R_i, R_j) = \frac{1}{T-1} \sum_{t=1}^{T} (R_{i,t} - \mu_i)(R_{j,t} - \mu_j). \tag{9}$$

Una covarianza positiva indica que dos activos tienden a presentar rendimientos superiores o inferiores a sus respectivos promedios en los mismos períodos. Una covarianza negativa indica una tendencia a moverse en sentidos opuestos.

4. Aplicación del algoritmo genético

Cada individuo o cromosoma representa una posible distribución de la cartera. Cada gen corresponde al porcentaje del capital asignado a un instrumento [3]. Para ocho activos, el cromosoma puede escribirse como:

$$w = [w_1, w_2, \ldots, w_8]. \tag{10}$$

La población está formada por múltiples distribuciones posibles [3]. En la implementación se utiliza una población de 100 individuos por generación. El objetivo de trabajar con una población es explorar simultáneamente diferentes regiones del espacio de soluciones.

4.1 Selección

Una vez calculado el fitness de cada individuo, las soluciones se ordenan de acuerdo con su desempeño. En la implementación se utiliza una estrategia de selección por truncamiento, mediante la cual se conserva la mitad superior de la población como conjunto de padres.

Dado que la población está compuesta por 100 individuos, se seleccionan los 50 individuos con mayor valor de fitness. Estos individuos son utilizados posteriormente como padres para generar la nueva población mediante los operadores de cruzamiento y mutación.

De esta forma, se favorece la permanencia de las soluciones con mejor desempeño, al mismo tiempo que se mantiene un conjunto de individuos suficientemente amplio para generar nuevas combinaciones.

4.2 Cruce

El cruzamiento permite combinar la información contenida en dos individuos seleccionados para generar una nueva solución. En la implementación se utiliza un cruzamiento aritmético, mediante el cual cada gen del hijo se obtiene como una combinación ponderada de los genes correspondientes de ambos padres:

$$h = \alpha p_1 + (1 - \alpha) p_2, \tag{11}$$

donde p_1 y p_2 representan los padres, h el individuo generado y α es un valor aleatorio comprendido entre cero y uno. La probabilidad de aplicar el cruzamiento se establece en 0.8.

Luego de generar el hijo, se reajustan sus pesos para garantizar que la distribución resultante cumpla las restricciones de inversión y que la suma de los pesos sea igual a uno.

4.3 Mutación

La mutación introduce pequeñas modificaciones aleatorias en los genes. Su función es mantener la diversidad de la población y permitir explorar soluciones que no necesariamente aparecerían mediante el cruzamiento. En la implementación, cada gen presenta una probabilidad del 5 % de mutar, agregándose una perturbación aleatoria con distribución normal y desviación estándar de 0.05.

Una vez aplicada la mutación, los pesos son ajustados para respetar la suma total del capital y las restricciones mínima y máxima.

5. Funciones de fitness

5.1 Fitness basado en λ

Como el problema presenta dos objetivos simultáneos, se implementa una función que permite combinarlos en un único valor:

$$Fitness_\lambda = E(R_p) - \lambda \sigma_p. \tag{12}$$

El parámetro λ controla la importancia relativa otorgada al riesgo. Un valor mayor aumenta la penalización aplicada a carteras volátiles, mientras que un valor menor permite que el rendimiento tenga mayor influencia.

El principal inconveniente de esta formulación es que el valor de λ debe ser determinado mediante un criterio externo al algoritmo. Por esta razón, el proyecto plantea analizar experimentalmente diferentes valores del parámetro.

5.2 Índice de Sharpe

Como alternativa al fitness basado en λ, se utiliza el Índice de Sharpe [2]. Este indicador permite evaluar la relación entre la rentabilidad de una cartera y el riesgo asumido para obtenerla:

$$S_p = \frac{E(R_p) - R_f}{\sigma_p}. \tag{13}$$

donde R_f representa la tasa de rendimiento del activo libre de riesgo [2].

En este caso el valor del Índice de Sharpe puede utilizarse directamente como función de fitness :

$$Fitness_{Sharpe} = S_p. \tag{14}$$

La principal diferencia respecto del criterio Lambda es que no se necesita establecer explícitamente un parámetro para ponderar el riesgo. La relación entre rentabilidad y riesgo se encuentra incorporada directamente en el cociente.

Ambas funciones permiten comparar cómo la elección del criterio de evaluación afecta la distribución final del capital.

6. Implementación

El programa se desarrolla en Python. La biblioteca *yfinance* se utiliza para obtener los datos históricos de mercado [4], mientras que *Pandas* permite organizar y procesar las series temporales [5] y *NumPy* realizar las operaciones numéricas y matriciales [6].

El flujo general de ejecución es el siguiente:

1. Obtener los precios históricos.
2. Calcular los retornos mensuales.
3. Obtener el rendimiento esperado de cada activo.
4. Calcular la matriz de covarianzas.
5. Generar la población inicial.
6. Evaluar el fitness de cada cartera.
7. Seleccionar los mejores individuos.
8. Aplicar cruzamiento y mutación.
9. Verificar las restricciones.
10. Generar la nueva población.
11. Repetir el proceso durante las generaciones establecidas.

La implementación permite registrar la evolución de las poblaciones. Esto posibilita representar gráficamente el comportamiento del algoritmo en el espacio formado por riesgo y rendimiento.

7. Resultados y análisis

El análisis de las generaciones con distintos λ permite observar cómo se modifica la distribución de las soluciones a medida que el algoritmo evoluciona con la variación del parámetro.

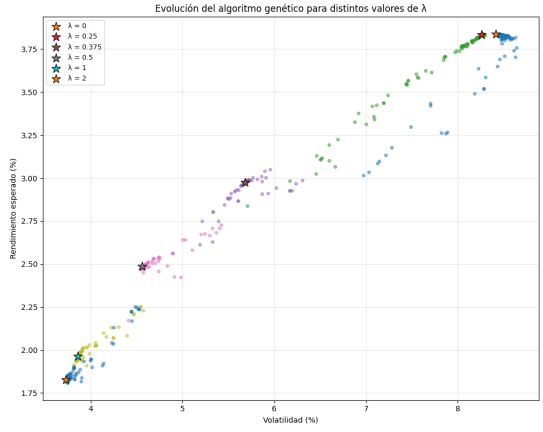


Figura 1: Evolución Algorítmica Comparativa utilizando diferentes valores de λ.

En las primeras generaciones se espera una mayor dispersión de los individuos, mientras que la selección favorece progresivamente las soluciones que presentan un mejor fitness. La mutación permite mantener diversidad y evitar que la población quede limitada a una única región del espacio de búsqueda.

La comparación entre ambas ejecuciones permite analizar si los criterios de fitness conducen a distribuciones diferentes. En particular, resulta relevante observar si una función produce carteras con mayor rendimiento, menor riesgo o una mejor relación entre ambas variables.

Cuadro 2: Comparación de las soluciones obtenidas utilizando un valor de λ y Sharpe.

Rendimiento (TEA)$^{(*)}$	$\lambda = 2$	**Sharpe**
Rendimiento	22,69 %	38,02 %
Riesgo	13,24 %	18,30 %
Fitness	-0,059242	0,515320

(*) TEA: Tasa Efectiva Anual, que representa el rendimiento anual considerando la capitalización de los rendimientos.

8. Trabajos relacionados

Mendizábal Zubeldia, Miera Zabalza y Zubia Zubiaurre [7] analizan la aplicación del modelo de Markowitz a la gestión de carteras en el mercado español. El trabajo estudia si el modelo puede proporcionar carteras con una mayor rentabilidad y un menor riesgo que las carteras representadas por los índices IBEX-35 e IGBM, mediante un análisis empírico de activos cotizados en dicho mercado.

El enfoque presentado en dicho trabajo utiliza el modelo de Markowitz como método de optimización, considerando la relación entre rentabilidad y riesgo para determinar carteras eficientes. Además, los autores señalan como una de las limitaciones del modelo la necesidad de estimar correctamente los rendimientos esperados y las covarianzas a partir de datos históricos.

El presente trabajo comparte con esta propuesta el objetivo de optimizar la distribución del capital considerando simultáneamente rentabilidad y riesgo. Sin embargo, se diferencia en el método utilizado para realizar la búsqueda de las ponderaciones: en lugar de resolver directamente el problema de optimización de Markowitz, se emplea un algoritmo genético que explora distintas distribuciones posibles de los activos. Asimismo, se comparan dos funciones de fitness, una basada en un parámetro de trade-off λ y otra basada en el Índice de Sharpe.

9. Conclusión y Trabajos futuros

La representación de cada cartera como un cromosoma permite convertir el problema financiero en un problema de búsqueda dentro de un espacio de soluciones. Las restricciones de inversión mínima y máxima permiten, además, incorporar condiciones adicionales sobre la distribución del capital.

La comparación entre el fitness basado en λ y el Índice de Sharpe permite estudiar dos criterios diferentes para establecer el compromiso entre rentabilidad y riesgo. El primero permite controlar explícitamente la penalización del riesgo, mientras que el segundo incorpora dicha relación directamente mediante un cociente.

Una limitación importante del enfoque es que los parámetros estadísticos utilizados por el modelo se estiman a partir de datos históricos. Por lo tanto, una cartera que resulte favorable durante el período analizado no implica necesariamente que presente el mismo comportamiento en períodos futuros.

Como trabajos futuros se plantea realizar múltiples ejecuciones independientes del algoritmo, agregar nuevas restricciones, estudiar la estabilidad de las soluciones y extender el modelo mediante técnicas de optimización multiobjetivo.

Agradecimientos

Se agradece a los docentes y colaboradores que brindaron orientación y acompañamiento durante el desarrollo del presente trabajo.

Referencias

[1] H. Markowitz, “Portfolio Selection,” *The Journal of Finance*, vol. 7, no. 1, pp. 77–91, 1952.

[2] W. F. Sharpe, “Mutual Fund Performance,” *The Journal of Business*, vol. 39, no. 1, pp. 119–138, 1966.

[3] J. H. Holland, *Adaptation in Natural and Artificial Systems*, University of Michigan Press, 1975.

[4] R. Aroussi, *yfinance: Download market data from Yahoo! Finance*, GitHub repository, 2017.

[5] W. McKinney, “Data Structures for Statistical Computing in Python,” in *Proceedings of the 9th Python in Science Conference*, pp. 51–56, 2010.

[6] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, et al., “Array programming with NumPy,” *Nature*, vol. 585, no. 7825, pp. 357–362, 2020. doi: 10.1038/s41586-020-2649-2.

[7] A. Mendizabal Zubeldia, L. M. Miera Zabalza y M. Zubia Zubiaurre, “El modelo de Markowitz en la gestión de carteras,” *Cuadernos de Gestión*, vol. 2, no. 1, pp. 33–46, 2002. doi: 10.5295/cdg.19217am.